UNIVERSIDADE FEDERAL DE MINAS GERAIS
ESCOLA DE ENGENHARIA

APRENDIZADO DE MÁQUINA - RELATÓRIO DA PRIMEIRA AULA

Nome: Gabriel de Araújo Costa Gomes
Matrícula: 2022102872

20 de outubro de 2024

Relatório da primeira aula de Aprendizado de Máquina

Aula 1
Análise Exploratória de Dados

20 de outubro de 2024

Conteúdo

1 Introdução **1**

2 Desenvolvimento e Metodologia **1**

3 Experimentos e Testes **2**

3.1 Carregamento de Dados 2
3.2 Descrição Estatística dos Dados 2
3.3 Matriz de Correlações 2
3.4 Matriz de Scatterplots 3
3.5 Boxplots 5

4 Conclusão **7**

5 Bibliografia **7**

1 Introdução

A aula prática realizada no dia 15 de Outubro de 2024 teve como objetivo de realizar uma análise exploratória completa, utlizando o dataset **Wine** com o intiuito identificar possíveis características irrelevantes e redundantes. Todos os gráficos gerados no Google Colab, com excessão dos Boxplots, foram obtidos com os códigos Python disponibilizados pelo professor Frederico Coelho no PDF de proposição de atividades.

2 Desenvolvimento e Metodologia

A seguir veremos os procedimentos realizados durantes as aulas.

1. **Carregamento de Dados:** O *dataset Wine* foi parcialmente carrregado com a utilização da biblioteca `sklearn`, possibilitando visualizar as primeiras linhas do *dataset*. Isso nos possibilitou observar as variáveis de entrada e saída

2. **Descrição Estatística dos Dados:** Com o objetivo de termos uma visão estatística dos dados, foi utilizado o comando `.describe()`. Isso facilitou analisármos a média, desvio padrão, e os valores máximos e mínimos de cada variável

3. **Matriz de Correlações:** Com o código disponibilizado pelo professor, foi contruído uma matriz de correlações para identificar as relações lineares entre as variáveis. Isso possibilitou a identificação de variáveis redundantes na nossa análise.

4. **Matriz de Scatterplots:** Com o código disponibilizado pelo professor, foi contruído uma matriz de Scatterplots para visualizar graficamente as relações entre as variáveis. Isso possibilitou identificar padrões e redundâncias que não eram evidentes na matriz de correlação.

5. **Boxplots:** Com o código disponibilizado pelo professor, que precisou ser melhorado pra uma visualização individual pra cada boxplot, foram gerados os gráficos de boxplots que permitiram observar a distribuição de cada variável em relação às classes da variável alvo. Isso ajudou a identificar variáveis que não variam muito entre as classes ou que tem distribuições similares entre elas.

3 Experimentos e Testes

Agora analizaremos todas as informações e relações de variáveis que foram explicitadas pelos gráficos e tabelas.

3.1 Carregamento de Dados

Como é possível ver na tabela 1, as variáveis de entrada são as características, que representam as propriedades químicas dos vinhos. Sendo estas: *alcohol, malic-acid, ash, alcalinity-of-ash, magnesium, total-phenols, flavanoids, nonflavanoid-phenols, proanthocyanins, color-intensity, hue, od280/od315-of-diluted-wines* e *proline*. A variável de saída é a variável *target*, que indica a classe de cada vinho, representando o tipo de vinho.

alcohol	malic_acid	ash	alcalinity_of_ash	magnesium	total_phenols	flavanoids	nonflavanoid_phenols	proanthocyanins	color_intensity	hue	od280/od315_of_diluted_wines	proline	target
14.23	1.71	2.43	15.6	127	2.80	3.06	0.28	2.29	5.64	1.04	3.92	1065	0
13.20	1.78	2.14	11.2	100	2.65	2.76	0.26	1.28	4.38	1.05	3.40	1050	0
13.16	2.36	2.67	18.6	101	2.80	3.24	0.30	2.81	5.68	1.03	3.17	1185	0
14.37	1.95	2.50	16.8	113	3.85	3.49	0.24	2.18	7.80	0.86	3.45	1480	0
13.24	2.59	2.87	21.0	118	2.80	2.69	0.39	1.82	4.32	1.04	2.93	735	0

Tabela 1: Tabela do carregamento parcial do *dataset* Wine.

3.2 Descrição Estatística dos Dados

A tabela 2 nos fornece uma visão geral estatística das variáveis, sendo elas a média, desvio padrão, valores mínimos e máximos de cada variável.

	alcohol	malic_acid	ash	alcalinity_of_ash	magnesium	total_phenols	flavanoids	nonflavanoid_phenols	proanthocyanins	color_intensity	hue	od280/od315_of_diluted_wines	proline	target
count	178.000	178.000	178.000	178.000	178.000	178.000	178.000	178.000	178.000	178.000	178.000	178.000	178.000	178.000
mean	13.001	2.336	2.367	19.495	99.742	2.295	2.029	0.362	1.591	5.058	0.957	2.612	746.893	0.938
std	0.812	1.117	0.274	3.340	14.282	0.626	0.999	0.124	0.572	2.318	0.229	0.710	314.907	0.775
min	11.030	0.740	1.360	10.600	70.000	0.980	0.340	0.130	0.410	1.280	0.480	1.270	278.000	0.000
25%	12.363	1.603	2.210	17.200	88.000	1.743	1.205	0.270	1.250	3.220	0.783	1.938	500.500	0.000
50%	13.050	1.865	2.360	19.500	98.000	2.355	2.135	0.340	1.555	4.690	0.965	2.780	673.500	1.000
75%	13.678	3.083	2.558	21.500	107.000	2.800	2.875	0.438	1.950	6.200	1.120	3.170	985.000	2.000
max	14.830	5.800	3.230	30.000	162.000	3.880	5.080	0.660	3.580	13.000	1.710	4.000	1680.000	2.000

Tabela 2: Estatísticas descritivas das características dos vinhos do dataset Wine.

3.3 Matriz de Correlações

Com a Matriz de correlações, mostrada na figura 1 abaixo, foi possível observar a forte correlação positiva entre as variáveis *total-phenols* e *flavanoids*. Podendo significar uma redundância e uma possível remoção do modelo. Essa é a unica

correlação forte entre variáveis pois o valor de correlação forte considerado foi de ±0.8, como sugerido na proposição da atividade.

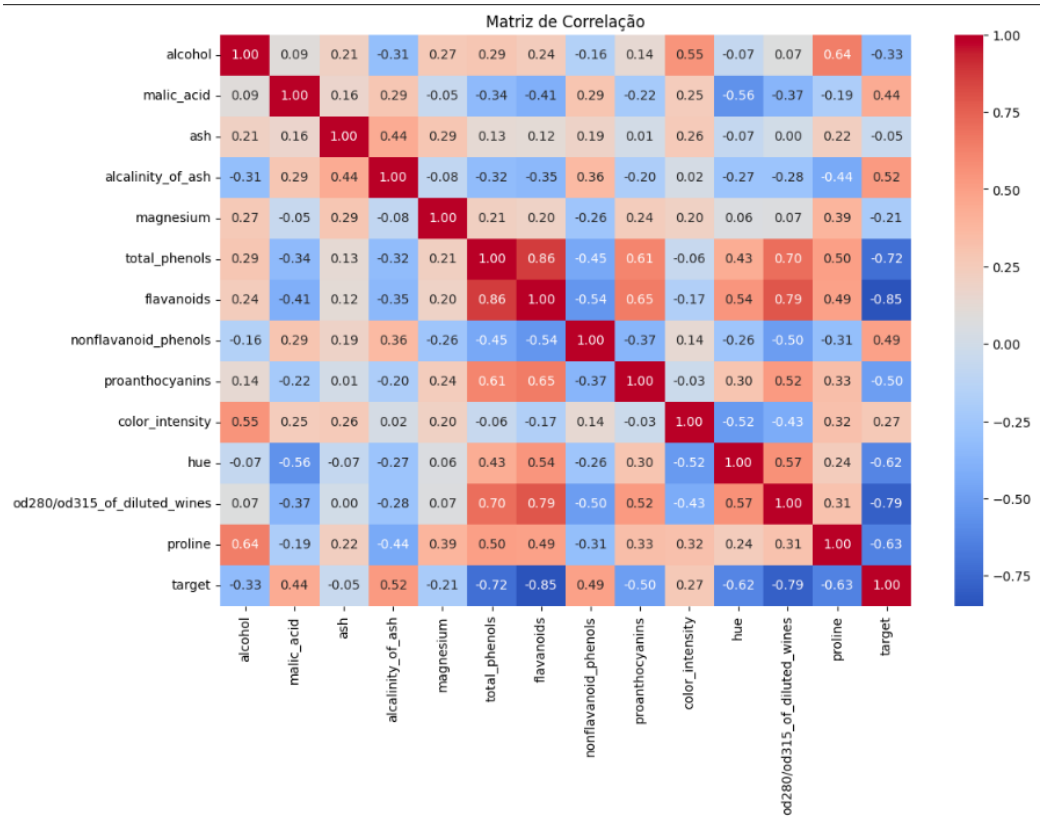

Figura 1: Matriz de Correlação.

3.4 Matriz de Scatterplots

Com a Matriz de scatterplots na figura 2, foi possível visualizar graficamente as relações entre as variáveis ajudando a identificar padrões ou redundâncias visuais que não ficaram evidentes na matriz de correlação.

Figura 2: Matriz de Scatterplots (gráficos de dispersão).

Foi identificado dois pares de variáveis que mostram padrões semelhantes. Sendo estes o par *total-phenols* e *flavanoids*, mostrado na figura 3, e o par *hue* e *od280/od315-of-diluted-wines*, mostrado na figura 4. Como é a segunda vez que observamos semelhanças fortes entre o par *total-phenols* e *flavanoids*, existem grandes indícios de redundância, que pode resultar na retirada de uma das variáveis.

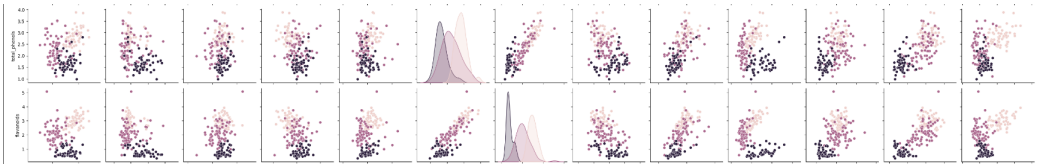

Figura 3: Semelhança entre *total-phenols* e *flavanoids*.

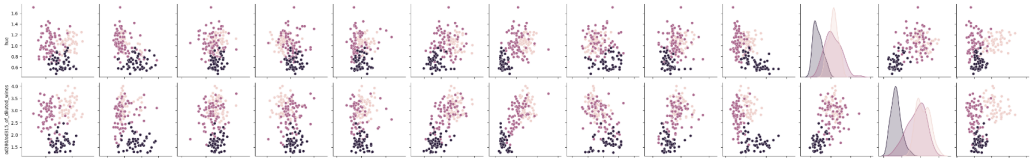

Figura 4: Semelhança entre *hue* e *od280/od315-of-diluted-wines*.

Além disso, como pode ser visto na figura 5, as variáveis *ash* e *alcalinity-of-ash* não separam bem as classes (uma superposição de classes), o que também pode indicar redundância.

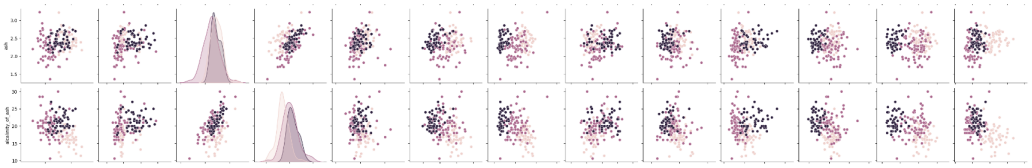

Figura 5: Superposição de classes em *ash* e *alcalinity-of-ash*.

3.5 Boxplots

Com os gráficos de boxplot, mostrados na figura 6, foi possível observar a distribuição de cada variável em relação às classes da variável alvo. Isso possibilitou identificar uma variável que não varia muito entre as classes, a variável *ash*, que é potencialmente irrelevante. Também foi possível identificar as variáveis apresentam outliers significativos, sendo estas: *alcohol, malic-acid, ash, alcalinity-of-ash, magnesium, flavanoids, proanthocyanins* e *hue*.

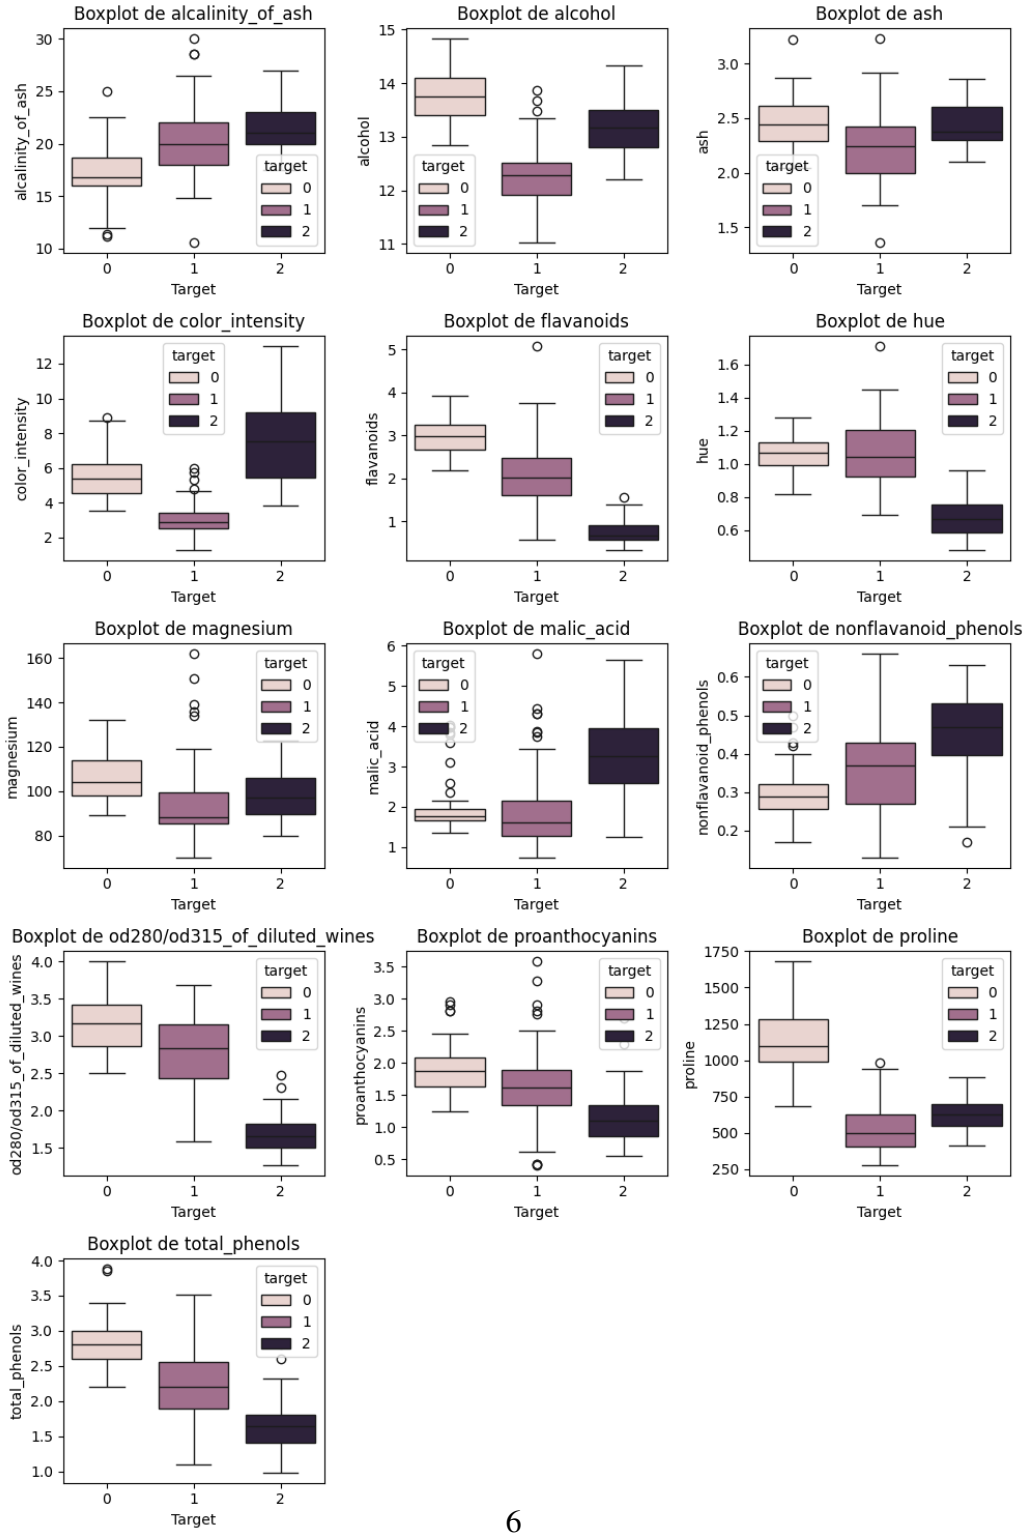

Figura 6: Boxplot.

4 Conclusão

Com base nas análises feitas, as variáveis *total-phenols* e *flavanoids* apresentaram alta correlação entre si, além de muitas semlhanças. Com base nisso, acredito que é redundânte o uso das duas variáveis no modelo, e penso que a exclusão de uma delas não alterariam os resultados.

Além disso, com base nos scatterplots e boxplots, a variável *ash* aparenta não distinguir as classes bem nos dois gráficos. Por isso, eu a consideraria irrelevante.

Então minha conclusão, com base nas observações feitas, é que para otimizar o modelo de classificação as variáveis *ash* e *flavanoids* (ou *total-phenols* em seu lugar) deveriam ser removidas.

5 Bibliografia

Referências

[1] BENTLEY. J.L. ”*Murphy, Kevin P. Probabilistic Machine Learning: An introduction*”. MIT press, 2022.